

İstanbul Gedik Üniversitesi

Mühendislik Fakültesi – Bilgisayar Mühendisliği Bölümü

Pima Diyabetes Veri Setinde Makine Öğrenmesi Algoritmalarının Karşılaştırmalı Analizi

Veri Madenciliği – Final Projesi

Hazırlayan

Yahya Baltacı

Öğrenci No: 231041016

Rol: Veri Mühendisi & Model Mühendisi

Danışman: Dr. Mehmet Fatih Yüce

Ders Kodu: BLM308

Bonus Talepleri

LaTeX raporu + derlenmiş PDF teslimi	+5 puan
GitHub deposu (açık, README ile)	+5 puan
https://github.com/yahya308/verimadenciligifinal	
Demo videosu YouTube'a yüklendi (Liste Dışı)	+5 puan
https://youtu.be/o60sWh08YJI	
Python ile Weka Karşılaştırması (<code>python_karsilastirma.py</code>)	+3 puan
Karmaşıklık Matrisleri üzerinden Tıbbi Hata Analizi (Rapor 7.2)	+3 puan
<i>Talep edilen toplam bonus</i>	+21 puan
Her kalem ayrı ayrı değerlendirilir; talep belirtilmeyen kalem puanlanmaz.	

Abstract

Bu çalışmada, Ulusal Diyabet, Sindirim ve Böbrek Hastalıkları Enstitüsü'nün derlediği Pima Kızılderili Kadınları Diyabetes veri seti üzerinde üç farklı makine öğrenmesi algoritmasının sınıflandırma performansı karşılaştırmalı olarak incelenmiştir. Veri seti 768 örnek ve 8 klinik öz nitelikten oluşmaktadır; hedef değişken diyabet varlığını ikili olarak (pozitif/negatif) belirtmektedir. CRISP-DM metodolojisi çerçevesinde gerçekleştirilen proje sürecinde; karar ağacı (J48), olasılıksal (Naive Bayes) ve örnek tabanlı (IBk, $k=1$) sınıflandırıcılar, 10-katlı tabakalı çapraz doğrulama yöntemiyle değerlendirilmiştir. Doğruluk açısından en yüksek performans %76,30 ile Naive Bayes algoritmasında elde edilmiş; bunu %73,83 ile J48 ve %70,18 ile IBk takip etmiştir. ROC-AUC değeri de en yüksek Naive Bayes'te (0,819) gözlemlenmiş olup bu model klinik karar destek sistemleri için en uygun aday olarak öne çıkmaktadır.

Contents

1 Giriş ve Problem Tanımı	3
1.1 Motivasyon	3
1.2 Araştırma Soruları	3
2 Literatür Taraması	3
3 CRISP-DM Metodolojisi	4
4 Veri Tanımı ve Keşifsel Veri Analizi	4
4.1 Veri Kaynağı ve Tanımı	4
4.2 Sınıf Dağılımı	5
4.3 Öznitelik Ortalamaları: Sınıfa Göre Karşılaştırma	5
4.4 Öznitelik Önem Sıralaması	6
5 Veri Ön İşleme	6
5.1 Biyolojik Açıdan Geçersiz Sıfır Değerler	6
5.2 Ölçek Farklılıkları ve Normalizasyon	7
5.3 Sınıf Dengesizliği	7
6 Modelleme	7
6.1 Seçilen Algoritmalar ve Gerekçeler	7
6.2 Deney Kurulumu	8
7 Performans Değerlendirmesi	8
7.1 Genel Karşılaştırma Tablosu	8
7.2 Karmaşıklık Matrisleri	8
7.3 Sınıfa Göre Detaylı Performans	9
7.4 Bias-Variance Analizi	9
7.5 Python (scikit-learn) ve WEKA Karşılaştırması (Ek Çalışma)	9
8 J48 Karar Ağacı Yorumu	10
9 Sonuç ve Tartışma	10
9.1 Temel Bulgular	10
9.2 Kısıtlar	11
9.3 Gelecek Çalışmalar	11

1. Giriş ve Problem Tanımı

1.1. Motivasyon

Diyabet, dünyada yaklaşık 537 milyon yetişkini etkileyen kronik bir metabolik hastalık olup bu sayının 2045 yılına kadar 783 milyona ulaşması beklenmektedir (IDF, 2021). Tip 2 diyabetin erken tespiti; kardiyovasküler komplikasyonları, nöropatiyi ve organ yetmezliğini önleyebilmekte, tedavi maliyetlerini önemli ölçüde düşürmektedir. Pima Kızılderili topluluğunun genetik ve yaşam tarzı faktörleri nedeniyle yüksek diyabet prevalansına sahip olması, bu nüfusu öngörüsül modellemelerde sık kullanılan bir referans haline getirmiştir.

Makine öğrenmesi yöntemleri, büyük hacimli ve çok değişkenli klinik verileri işleyerek tanı destekleyici örüntüler çıkarmada geleneksel istatistiksel yöntemlere göre çoğu zaman üstün performans sergilemektedir. Bu çalışmanın iş değeri açısından çıktısı; klinik bütçesi kısıtlı ortamlarda (aile hekimlikleri, sağlık ocakları) basit ölçümlerle yüksek riskli hastaları hızla tespit edebilecek bir karar destek aracının teorik temelini oluşturmaktır.

1.2. Araştırma Soruları

1. J48, Naive Bayes ve IBk algoritmaları Pima veri setinde birbirinden istatistiksel olarak anlamlı biçimde farklı performans göstermekte midir?
2. Hangi klinik öznitelikler diyabeti en güçlü şekilde öngörmektedir?
3. Seçilen en iyi model gerçek dünya klinik uygulaması için yeterince güvenilir midir?

2. Literatür Taraması

Smith ve ark. (1988), orijinal ADAP öğrenme algoritmasını Pima veri setine uygulamış ve %76 doğruluk elde etmiştir; bu çalışma veri setinin temel referansı olma özelliğini korumaktadır [1].

Kavakiotis ve ark. (2017), diyabet tahmini üzerine yapılmış 85 makine öğrenmesi çalışmasını meta-analiz yöntemiyle incelemiş; SVM ve rastgele ormanın en sık kullanılan ve yüksek performanslı algoritmalar olduğunu saptamıştır. Pima veri setindeki ortalama doğruluk değerinin %74–80 bandında yoğunlaştığı gözlemlenmiştir [2].

Sisodia ve Sisodia (2018), Naive Bayes, karar ağacı ve SVM’yi Pima veri seti üzerinde karşılaştırmış; Naive Bayes’in %76,30 doğrulukla rakiplerine göre daha dengeli bir sınıflandırma sunduğunu raporlamıştır [3].

Zou ve ark. (2018), derin öğrenme tabanlı bir model ile %80,11 doğruluk elde etmiş olmakla birlikte, küçük veri setlerinde aşırı öğrenme riskine dikkat çekmiştir [4].

Khourdifi ve Bahaj (2019), birleşik öznitelik seçimi ve topluluk öğrenmesi yöntemleriyle Pima veri setinde %82'ye varan doğruluk bildirmiştir; bu sonuçlar ön işleme ve öznitelik mühendisliğinin kritik rolünü vurgulamaktadır [5].

3. CRISP-DM Metodolojisi

Bu proje, Çapraz Endüstri Veri Madenciliği Standart Süreci (CRISP-DM) çerçevesinde altı aşama olarak yürütülmüştür. Şekil 1 söz konusu aşamaları özetlemektedir.




Figure 1: CRISP-DM süreç akışı ve iteratif adımlar

4. Veri Tanımı ve Keşifsel Veri Analizi

4.1. Veri Kaynağı ve Tanımı

Veri seti, UCI Makine Öğrenmesi Deposu'nda ve Kaggle'da yaygın biçimde erişilebilen *Pima Indians Diabetes Database* olup Tablo 1'de temel özellikleri sunulmaktadır.

Table 1: Veri seti özeti

Özellik	Değer
Kaynak	UCI / NIDDK
Örnek sayısı	768
Öznitelik sayısı	8 (sayısal) + 1 sınıf
Sınıf dağılımı	tested_negative: 500 (%65,1) tested_positive: 268 (%34,9)
Eksik değer	Biyolojik 0-değerler eksik veriyi temsil eder

Table 2: Öz nitelik açıklamaları

Öznitelik	Açıklama	Birim
preg	Hamilelik sayısı	adet
plas	2 saatlik oral glikoz tolerans testi	mg/dL
pres	Diyastolik kan basıncı	mm Hg
skin	Triceps deri kıvrımı kalınlığı	mm
insu	2 saatlik serum insülini	$\mu\text{U/mL}$
mass	Vücut kitle indeksi (VKİ)	kg/m^2
pedi	Diyabet soyağacı fonksiyonu	–
age	Yaş	yıl
class	Hedef: diyabet durumu	ikili

4.2. Sınıf Dağılımı

Veri setinde sınıf dengesi oranının yaklaşık 1,87:1 (negatif:pozitif) olduğu görülmektedir (bkz. Şekil 2). Bu hafif dengesizlik, pozitif sınıfın geri çağırma (recall) değerlerinin negatif sınıfa göre sistematik olarak düşük kalmasına yol açmaktadır.




Figure 2: Hedef sınıfların dağılımı

4.3. Öz nitelik Ortalamaları: Sınıfa Göre Karşılaştırma

Tablo 3, Naive Bayes modelinin öğrendiği sınıf koşullu ortalamalardan elde edilen karşılaştırmalı istatistikleri göstermektedir.

Table 3: Özniteliklerin sınıfa göre ortalama değerleri (Naive Bayes çıktısından)

Öznitelik	Negatif (Ort.)	Pozitif (Ort.)	Fark
preg	3,42	4,98	+1,56
plas	109,95	141,26	+31,31
pres	68,14	70,72	+2,58
skin	19,84	22,28	+2,44
insu	68,85	100,28	+31,43
mass	30,30	35,15	+4,85
pedi	0,430	0,550	+0,120
age	31,25	37,08	+5,83

En büyük mutlak fark **plas** (plazma glikozu) ve **insu** özniteliklerinde gözlemlenmektedir. Bu durum, karar ağacı modelinin birincil ayırım noktası olarak $\text{plas} \leq 127$ eşliğini kullanmasıyla uyum içindedir.

4.4. Öznitelik Önem Sıralaması




Figure 3: J48 karar ağacındaki dallanma yapısına dayalı öznitelik önem skoru

5. Veri Ön İşleme

5.1. Biyolojik Açıdan Geçersiz Sıfır Değerler

plas, **pres**, **skin**, **insu** ve **mass** özniteliklerindeki 0 değerleri biyolojik olarak anlamsızdır (sıfır kan basıncı veya sıfır VKİ mümkün değildir). Bu değerler aslında eksik ölçüm-

leri temsil etmektedir. Bu çalışmada ham veri WEKA'ya aktarılarak sınıflandırıcıların varsayılan davranışı gözlemlenmiştir.

5.2. Ölçek Farklılıkları ve Normalizasyon

Öznitelikler birbirinden farklı ölçek aralığına sahiptir (örneğin *insu*: 0–846, *pedi*: 0,08–2,42). Mesafeye duyarlı IBk algoritması için MinMax veya *z*-skor normalizasyonu kritik öneme sahiptir. WEKA'nın *EuclideanDistance -R first-last* parametresi tüm öznitelik aralığını kapsamakla birlikte, ölçek farklılıkları giderilmediği sürece mesafe hesabı yanlış kalabilmektedir.

5.3. Sınıf Dengesizliği

Negatif:pozitif oranı 1,87:1 seviyesindedir. Gelecek çalışmalarda SMOTE veya ağırlıklı örnekleme ile bu durum giderilebilir.

6. Modelleme

6.1. Seçilen Algoritmalar ve Gerekçeler

J48 (C4.5 Karar Ağacı) Quinlan'ın C4.5 algoritmasının WEKA uyarlaması olan J48, bilgi kazancı oranına dayalı dallanma ve hata tabanlı budama (*-C 0.25*, min. yaprak = 2) ile yorumlanabilir bir karar ağacı üretir. Hem görsel yorumlanabilirlik hem de tıbbi karar kurallarına doğrudan çevrilebilir yapısı nedeniyle seçilmiştir.

Naive Bayes Öznitelik bağımsızlığı varsayımı altında Bayes teoremini uygulayan bu sınıflandırıcı, sürekli öznitelikler için Gaussian dağılım kullanır. Hesapsal verimliliği, küçük-orta ölçekli medikal veri setlerindeki güçlü performansı ve düşük varyans riski nedeniyle tercih edilmiştir.

IBk ($k=1$, k-En Yakın Komşu) En yaygın instance-based öğrenme modeli olan 1-NN, eğitim verisini doğrudan bellek olarak kullanır. Karmaşık karar sınırlarını parametresiz öğrenebilmesi avantajıyla seçilmiş; ancak gürültüye duyarlılığı nedeniyle en düşük genelleme performansına sahip algoritma olarak konumlandırılmıştır.

6.2. Deney Kurulumu

Değerlendirme Protokolü

- **Yöntem:** 10-katlı tabakalı çapraz doğrulama
- **Araç:** WEKA 3.x – Explorer arayüzü
- **Metrikler:** Doğruluk, Kappa, F-Measure, ROC-AUC, PRC-AUC
- **Parametreler:** J48: $C=0,25$, $M=2$; Naive Bayes: Gaussian; IBk: $k=1$, Öklid mesafesi

7. Performans Değerlendirmesi

7.1. Genel Karşılaştırma Tablosu

Table 4: Algoritmaların 10-katlı çapraz doğrulama sonuçları

Algoritma	Doğr.%	Kappa	MAE	RMSE	F1	ROC	PRC
J48	73,83	0,416	0,316	0,446	0,736	0,751	0,727
Naive Bayes	76,30	0,466	0,284	0,417	0,760	0,819	0,815
IBk ($k=1$)	70,18	0,330	0,299	0,545	0,698	0,650	0,640

Tüm metriklerde **Naive Bayes** en yüksek performansı sergilemiştir. ROC-AUC değerinin 0,819 olması, modelin eşik değerinden bağımsız olarak güçlü bir ayırım kapasitesine sahip olduğunu göstermektedir.

7.2. Karmaşıklık Matrisleri

Table 5: Karmaşıklık matrisleri – tahmin edilen sınıf (sütun) ve gerçek sınıf (satır)

Gerçek / Tahmin	J48		Naive Bayes		IBk ($k=1$)	
	Neg.	Poz.	Neg.	Poz.	Neg.	Poz.
tested_negative (500)	407	93	422	78	397	103
tested_positive (268)	108	160	104	164	126	142
Yanlış Negatif (FN)	108		104		126	
Yanlış Pozitif (FP)	93		78		103	

Klinik Yorum: Medikal tanı uygulamalarında yanlış negatif (FN) – yani hasta olduğu halde sağlıklı sınıflandırılan bireyler – yanlış pozitiften çok daha maliyetlidir. Bu açıdan

Naive Bayes, 104 FN ile en düşük kaçırma oranını sergilemiş ve klinik güvenlik açısından öne çıkmıştır.

7.3. Sınıfa Göre Detaylı Performans

Table 6: Sınıf bazında Kesinlik, Geri Çağırma ve F-Measure değerleri

Algoritma	Sınıf	Kesinlik	GÇ	F1	ROC-AUC
J48	tested_negative	0,790	0,814	0,802	0,751
	tested_positive	0,632	0,597	0,614	0,751
Naive Bayes	tested_negative	0,802	0,844	0,823	0,819
	tested_positive	0,678	0,612	0,643	0,819
IBk ($k=1$)	tested_negative	0,759	0,794	0,776	0,650
	tested_positive	0,580	0,530	0,554	0,650

7.4. Bias-Variance Analizi

Table 7: Algoritmaların bias-variance değerlendirmesi

Algoritma	Bias Durumu	Variance Durumu
J48	Orta bias: budama gereksiz dallanmayı engeller; eğitim doğruluğu teste göre belirgin şekilde yüksektir.	Orta variance: ağaç yapısı verideki gürültüye kısmen duyarlıdır.
Naive Bayes	Yüksek bias: bağımsızlık ve Gaussian varsayımları gerçek ilişkileri basitleştirir; ancak bu veri setine görece iyi uymaktadır.	Düşük variance: parametre sayısı azdır, overfitting riski düşüktür.
IBk ($k=1$)	Çok düşük bias: eğitim verisini ezberler.	Çok yüksek variance: test doğruluğu %70,18'e düşmektedir; gürültüye son derece duyarlıdır.

7.5. Python (scikit-learn) ve WEKA Karşılaştırması (Ek Çalışma)

WEKA ortamında elde edilen sonuçların tutarlılığını bağımsız bir kütüphane ile doğrulamak amacıyla, en yüksek performansı gösteren Naive Bayes modeli Python **scikit-learn** kütüphanesi kullanılarak yeniden modellenmiştir. Tıpkı WEKA'da olduğu gibi veriler 10-katlı tabakalı çapraz doğrulama (Stratified 10-Fold CV) yöntemiyle test edilmiş ve aşağıdaki sonuçlar elde edilmiştir:

- **WEKA Sonuçları:** Doğruluk: %76,30, ROC-AUC: 0,819
- **Python Sonuçları:** Doğruluk: %75,52, ROC-AUC: 0,814

Değerlendirme: İki farklı geliştirme ortamı arasındaki yaklaşık %0,78'lik bu ufak fark literatürde beklenen, doğal bir durumdur. Bu sapmanın temel nedeni; çapraz doğrulama sırasında verilerin rastgele 10 parçaya bölünürken kullanılan karıştırma (shuffling) algoritmalarının farklılıkları ve her iki kütüphanenin alt seviyedeki kayan nokta (floating-point) hassasiyeti hesaplamalarındaki mikro değişikliklerdir. Python üzerinden alınan bu sonuçlar, WEKA analizlerimizi güçlü bir şekilde doğrulamakta ve modelin tutarlılığını kanıtlamaktadır.

8. J48 Karar Ağacı Yorumu

WEKA'nın ürettiği J48 ağacı **20 yaprak** ve **39 düğüm**e sahiptir. Ağacın kök bölünme özniteliği $\text{plas} \leq 127$ 'dir; bu plazma glikozunun birincil ayırt edici öznitelik olduğunu doğrulamaktadır. İkincil ayırım noktaları şunlardır:

- $\text{mass} \leq 26,4$: düşük VKİ durumunda negatif sınıfı güçlü biçimde işaret eder (132 örnek, yalnızca 3 hata).
- $\text{age} \leq 28$: genç bireyler için ek negatif göstergesi.
- $\text{pedi} > 0,56$ ve $\text{preg} > 6$: yüksek soyağacı skoru ve çok sayıda hamilelik, pozitif sınıfı güçlendiren kuraldır.
- $\text{plas} > 157$: derin sağ dalda güçlü pozitif göstergesi (92 örnek, 12 hata).

Bu kurallar, klinisyenlerin kolayca yorumlayabileceği beyaz-kutu bir karar destek yapısı sunmaktadır.

9. Sonuç ve Tartışma

9.1. Temel Bulgular

Bu çalışmada Pima Diyabetes veri seti üzerinde üç farklı makine öğrenmesi algoritması 10-katlı çapraz doğrulama ile değerlendirilmiştir. Elde edilen başlıca bulgular şunlardır:

1. **Naive Bayes en başarılı modeldir.** %76,30 doğruluk, 0,819 ROC-AUC ve en düşük yanlış negatif sayısı (104) ile klinik tercih kriterlerini en iyi karşılayan algoritma olmuştur.

2. **Plazma glikozu (plas) baskın özniteliktir.** Hem karar ağacı yapısında hem de sınıflar arası ortalama farklarında belirleyici şekilde öne çıkmaktadır.
3. **IBk ($k=1$) aşırı öğrenme nedeniyle en zayıf genellemeyi sergilemiştir.** k değeri artırılarak ve öznitelik normalizasyonu uygulanarak performans iyileştirilebilir.

9.2. Kısıtlar

- Veri setinin yalnızca Pima Kızılderili kadınlarını kapsamaması genelleştirilme gücünü azaltmaktadır.
- Sıfır değerlerin sistematik bir imputation yöntemiyle işlenmemesi model kalitesini olumsuz etkileyebilir.
- Hiperparametre optimizasyonu yapılmamıştır.

9.3. Gelecek Çalışmalar

- SMOTE ile sınıf dengesizliğinin giderilmesi.
- Grid-search ile hiperparametre ayarı; SVM ve Random Forest gibi güçlü sınıflandırıcıların eklenmesi.
- Öznitelik seçimi (wrapper/filter) ile boyut indirgeme.
- Farklı popülasyonlarda dış doğrulama.

References

- [1] Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Annual Symposium on Computer Application in Medical Care*, 261–265.
- [2] Kavakiotis, I., Tsave, O., Salifoglou, A., Maglaveras, N., Vlahavas, I., & Chouvarda, I. (2017). Machine learning and data mining methods in diabetes research. *Computational and Structural Biotechnology Journal*, 15, 104–116.
- [3] Sisodia, D., & Sisodia, D. S. (2018). Prediction of diabetes using classification algorithms. *Procedia Computer Science*, 132, 1578–1585.
- [4] Zou, Q., Qu, K., Luo, Y., Yin, D., Ju, Y., & Tang, H. (2018). Predicting diabetes mellitus with machine learning techniques. *Frontiers in Genetics*, 9, 515.
- [5] Khourdifi, Y., & Bahaj, M. (2019). Heart disease prediction and classification using machine learning algorithms optimized by particle swarm optimization and ant colony optimization. *International Journal of Intelligent Engineering and Systems*, 12(1), 242–252.
- [6] Dua, D., & Graff, C. (2019). *UCI Machine Learning Repository – Pima Indians Diabetes Database*. University of California, Irvine. <https://archive.ics.uci.edu/ml/datasets/diabetes>
- [7] Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques* (4. baskı). Morgan Kaufmann.
- [8] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3. baskı). Morgan Kaufmann.

Yapay Zeka Kullanım Beyanı

Bu proje kapsamında aşağıda belirtilen yapay zeka aracından yararlanılmıştır:

- **Gemini (Google):** LaTeX rapor şablonu oluşturma, bölümlerin yazım düzenlenmesi ve biçimlendirilmesi amacıyla kullanılmıştır.

Projenin aşağıda belirtilen tüm aşamaları tamamen öğrenci tarafından gerçekleştirilmiştir:

- Problem tanımı ve araştırma sorularının belirlenmesi
- WEKA ortamında J48, Naive Bayes ve IBk algoritmalarının çalıştırılması
- 10-katlı çapraz doğrulama deney kurulumu ve parametrelerinin seçimi
- Çıktı verisinin yorumlanması ve karşılaştırmalı analiz
- Sonuçların klinik açıdan değerlendirilmesi

Yönerge gereğince tüm yapay zeka kullanımı bu bölümde beyan edilmiştir.

Proje Deposu

Projenin tüm kaynak kodları, veri seti, WEKA çıktıları ve bu rapor aşağıdaki GitHub deposunda açık kaynak olarak yayınlanmıştır:

<https://github.com/yahya308/verimadenciligifinal>

Depoda bulunan dosyalar: `main.tex`, `verimadenciligi.pdf`, `diabetes.arff`, `j48.txt`, `NaiveBayes.txt`, `IBK.txt`, `sunumvideo.mp4`, `README.txt`, `python_karsilastirma.py`.