

[İSTANBUL GEDİK ÜNİVERSİTESİ]

Muhendislik Fakültesi – Bilgisayar Muhendisliği Bölümü

Pima Diyabetes Veri Setinde Makine Öğrenmesi Algoritmalarının Karşılaştırmalı Analizi

Veri Madenciliği – Final Projesi

Hazırlayan

[Yahya BALTACI]

Oğrenci No: [231041016]

Rol: Veri Muhendisi & Model Muhendisi

Öğretmen: [Doktor MEHMET FATİH YÜCE]

Ders Kodu: [BLM308]

May 12, 2026

Abstract

Bu calismada, Ulusal Diyabet, Sindirim ve Bobrek Hastaliklari Enstitusu'nun derledigini Pima Kizilderili Kadnlari Diyabetes veri seti uzerinde uc farkli makine ogrenmesi algoritmasinin siniflandirma performansi karsilastirmali olarak incelenmistir. Veri seti 768 ornek ve 8 klinik oznitelikten olusmaktadir; hedef degisken diyabet varligini ikili olarak (pozitif/negatif) belirtmektedir. CRISP-DM metodolojisi cercevesinde gerceklestirilen proje surecinde; karar agaci (J48), olasiliksal (Naive Bayes) ve ornek tabanli (IBk, $k=1$) siniflandiricilar, 10-katli tabakali capraz dogrulama yontemiyle degerlendirilmistir. Dogruluk acisindan en yuksek performans %76,30 ile Naive Bayes algoritmasinda elde edilmis; bunu %73,83 ile J48 ve %70,18 ile IBk takip etmistir. ROC-AUC degeri de en yuksek Naive Bayes'te (0,819) gozlemlenmis olup bu model klinik karar destek sistemleri icin en uygun aday olarak one cikmaktadir.

Contents

1	Giris ve Problem Tanimi	3
1.1	Motivasyon	3
1.2	Arastirma Sorulari	3
2	Literatur Taramasi	3
3	CRISP-DM Metodolojisi	4
4	Veri Tanimi ve Kesifsel Veri Analizi	4
4.1	Veri Kaynagi ve Tanimi	4
4.2	Sinif Dagilimi	5
4.3	Oznitelik Ortalamalari: Sinifa Gore Karsilastirma	5
4.4	Oznitelik Onem Siralamasi	6
5	Veri On Isleme	6
5.1	Biyolojik Acidan Gecersiz Sifir Degerler	6
5.2	Olcek Farkliliklari ve Normalizasyon	7
5.3	Sinif Dengesizligi	7
6	Modelleme	7
6.1	Secilen Algoritmalar ve Gerekceler	7
6.2	Deney Kurulumu	8
7	Performans Degerlendirmesi	8
7.1	Genel Karsilastirma Tablosu	8
7.2	Karmasiklik Matrisleri	8
7.3	Sinifa Gore Detayli Performans	9
7.4	Bias-Variance Analizi	9
8	J48 Karar Agaci Yorumu	9
9	Sonuc ve Tartisma	10
9.1	Temel Bulgular	10
9.2	Kisitlar	10
9.3	Gelecek Calismalar	11

1. Giriş ve Problem Tanımı

1.1. Motivasyon

Diyabet, dünyada yaklaşık 537 milyon yetiskini etkileyen kronik bir metabolik hastalık olup bu sayının 2045 yılına kadar 783 milyona ulaşması beklenmektedir (IDF, 2021). Tip 2 diyabetin erken tespiti; kardiyovasküler komplikasyonları, noropatiyi ve organ yetmezliğini önleyebilmekte, tedavi maliyetlerini önemli ölçüde düşürmektedir. Pima Kızılderili topluluğunun genetik ve yaşam tarzı faktörleri nedeniyle yüksek diyabet prevalansına sahip olması, bu nüfusu onkorusal modellemelerde sık kullanılan bir referans haline getirmiştir.

Makine öğrenmesi yöntemleri, büyük hacimli ve çok değişkenli klinik verileri işleyerek tanı destekleyici sonuçlar çıkarmada geleneksel istatistiksel yöntemlere göre çok zaman üstün performans sergilemektedir. Bu çalışmanın iş değeri açısından çıktısı; klinik bütçesi kısıtlı ortamlarda (aile hekimlikleri, sağlık ocakları) basit ölçümlerle yüksek riskli hastaları hızla tespit edebilecek bir karar destek aracının teorik temelini oluşturmaktır.

1.2. Araştırma Soruları

1. J48, Naive Bayes ve IBk algoritmaları Pima veri setinde birbirinden istatistiksel olarak anlamlı biçimde farklı performans göstermekte midir?
2. Hangi klinik özellikler diyabeti en güçlü şekilde öngörmektedir?
3. Seçilen en iyi model gerçek dünya klinik uygulaması için yeterince güvenilir midir?

2. Literatur Taraması

Smith ve ark. (1988), orijinal ADAP öğrenme algoritmasını Pima veri setine uygulamış ve %76 doğruluk elde etmiştir; bu çalışma veri setinin temel referansı olma özelliğini korumaktadır [1].

Kavakiotis ve ark. (2017), diyabet tahmini üzerine yapılmış 85 makine öğrenmesi çalışmasını meta-analiz yöntemiyle incelemiş; SVM ve rastgele ormanın en sık kullanılan ve yüksek performanslı algoritmalar olduğunu saptamıştır. Pima veri setindeki ortalama doğruluk değerinin %74–80 bandında yoğunlaştığı gözlemlenmiştir [2].

Sisodia ve Sisodia (2018), Naive Bayes, karar ağacı ve SVM’yi Pima veri seti üzerinde karşılaştırmış; Naive Bayes’in %76,30 doğrulukla rakiplerine göre daha dengeli bir sınıflandırma sunduğunu raporlamıştır [3].

Zou ve ark. (2018), derin ogrenme tabanlı bir model ile %80,11 dogruluk elde etmis olmakla birlikte, kucuk veri setlerinde asiri ogrenme riskine dikkat cekmistir [4].

Khourdifi ve Bahaj (2019), birlesik oznitelik secimi ve topluluk ogrenmesi yontemleriyle Pima veri setinde %82'ye varan dogruluk bildirmistir; bu sonuclar on isleme ve oznitelik muhendisliginin kritik rolunu vurgulamaktadir [5].

3. CRISP-DM Metodolojisi

Bu proje, Capraz Endustri Veri Madenciligi Standart Sureci (CRISP-DM) cercevesinde alti asama olarak yurutulmustur. Sekil 1 sozkonu asamalari ozetlemektedir.




Figure 1: CRISP-DM surec akisi ve iteratif adimlar

4. Veri Tanimi ve Kesifsel Veri Analizi

4.1. Veri Kaynagi ve Tanimi

Veri seti, UCI Makine Ogrenmesi Deposu'nda ve Kaggle'da yaygin bicimde erisilebilen *Pima Indians Diabetes Database* olup Tablo 1'de temel ozellikleri sunulmaktadır.

Table 1: Veri seti ozeti

Ozellik	Deger
Kaynak	UCI / NIDDK
Ornek sayisi	768
Oznitelik sayisi	8 (sayisal) + 1 sinif
Sinif dagilimi	tested_negative: 500 (%65,1) tested_positive: 268 (%34,9)
Eksik deger	Biyolojik 0-degerler eksik veriyi temsil eder

Table 2: Oznitelik aciklamalari

Oznitelik	Aciklama	Birim
preg	Hamilelik sayisi	adet
plas	2 saatlik oral glikoz tolerans testi	mg/dL
pres	Diyastolik kan basinci	mm Hg
skin	Triceps deri kivrimi kalinaligi	mm
insu	2 saatlik serum insulini	$\mu\text{U/mL}$
mass	Vucut kitle indeksi (VKI)	kg/m^2
pedi	Diyabet soyagaci fonksiyonu	–
age	Yas	yil
class	Hedef: diyabet durumu	ikili

4.2. Sinif Dagilimi

Veri setinde sinif dengesi oraninin yaklasik 1,87:1 (negatif:pozitif) oldugu gorulmektedir (bkz. Sekil 2). Bu hafif dengesizlik, pozitif sinifin geri cagirma (recall) degerlerinin negatif sinife gore sistematik olarak dusuk kalmasina yol acmaktadir.




Figure 2: Hedef siniflarin dagilimi

4.3. Oznitelik Ortalamalari: Sinifa Gore Karsilastirma

Tablo 3, Naive Bayes modelinin ogrendigi sinif kosullu ortalamalardan elde edilen karsilastirmali istatistikleri gostermektedir.

Table 3: Ozniteliklerin sinifa gore ortalama degerleri (Naive Bayes ciktisindan)

Oznitelik	Negatif (Ort.)	Pozitif (Ort.)	Fark
preg	3,42	4,98	+1,56
plas	109,95	141,26	+ 31,31
pres	68,14	70,72	+2,58
skin	19,84	22,28	+2,44
insu	68,85	100,28	+31,43
mass	30,30	35,15	+ 4,85
pedi	0,430	0,550	+0,120
age	31,25	37,08	+5,83

En buyuk mutlak fark **plas** (plazma glikozu) ve **insu** ozniteliklerinde gozlemlenmektedir. Bu durum, karar agaci modelinin birincil ayrim noktasi olarak $\text{plas} \leq 127$ esigini kullanmasiyla uyum icindedir.

4.4. Oznitelik Onem Sirlaması




Figure 3: J48 karar agacindaki dallanma yapısına dayali oznitelik onem skoru

5. Veri On Isleme

5.1. Biyolojik Acidan Gecersiz Sifir Degerler

plas, **pres**, **skin**, **insu** ve **mass** ozniteliklerindeki 0 degerleri biyolojik olarak anlamsizdir (sifir kan basinci veya sifir VKI mumkun degildir). Bu degerler aslinda eksik olcun-

leri temsil etmektedir. Bu calismada ham veri WEKA'ya aktarilarak siniflandiricilarin varsayilan davranisi gozlemlenmistir.

5.2. Olcek Farkliliklari ve Normalizasyon

Oznitelikler birbirinden farkli olcek araligina sahiptir (ornegin `insu`: 0–846, `pedi`: 0,08–2,42). Mesafeye duyarli IBk algoritmasi icin MinMax veya z -skor normalizasyonu kritik oneme sahiptir. WEKA'nin `EuclideanDistance -R first-last` parametresi tum oznitelik araligini kapsamakla birlikte, olcek farkliliklari giderilmedigi surece mesafe hesabi yanli kalabilmektedir.

5.3. Sinif Dengesizligi

Negatif:pozitif orani 1,87:1 seviyesindedir. Gelecek calismalarda SMOTE veya agirlikli ornekleme ile bu durum giderilebilir.

6. Modelleme

6.1. Secilen Algoritmalar ve Gerekceler

J48 (C4.5 Karar Agaci) Quinlan'in C4.5 algoritmasinin WEKA uyarlamasi olan J48, bilgi kazanci oranina dayali dallanma ve hata tabanli budama (`-C 0.25`, min. yaprak = 2) ile yorumlanabilir bir karar agaci uretir. Hem gorsel yorumlanabilirlik hem de tibbi karar kurallarina dogrudan cevriyebilir yapisi nedeniyle secilmistir.

Naive Bayes Oznitelik bagimsizligi varsayimi altinda Bayes teoremini uygulayan bu siniflandirici, surekli oznitelikler icin Gaussian dagilim kullanir. Hesapsal verimliliği, kucuk-orta olcekli medikal veri setlerindeki guclu performansi ve dusuk varyans riski nedeniyle tercih edilmistir.

IBk ($k=1$, k-En Yakın Komsu) En yaygin instance-based ogrenme modeli olan 1-NN, egitim verisini dogrudan bellek olarak kullanir. Karmasik karar sinirlarini parametresiz ogrenebilmesi avantajıyla secilmis; ancak gurutuye duyarliliği nedeniyle en dusuk genelleme performansina sahip algoritma olarak konumlandirilmistir.

6.2. Deney Kurulumu

Degerlendirme Protokolu

- **Yontem:** 10-katli tabakali capraz dogrulama
- **Arac:** WEKA 3.x – Explorer arayuzu
- **Metrikler:** Dogruluk, Kappa, F-Measure, ROC-AUC, PRC-AUC
- **Parametreler:** J48: $C=0,25$, $M=2$; Naive Bayes: Gaussian; IBk: $k=1$, Oklid mesafesi

7. Performans Degerlendirmesi

7.1. Genel Karsilastirma Tablosu

Table 4: Algoritmaların 10-katli capraz dogrulama sonuclari

Algoritma	Dogr.%	Kappa	MAE	RMSE	F1	ROC	PRC
J48	73,83	0,416	0,316	0,446	0,736	0,751	0,727
Naive Bayes	76,30	0,466	0,284	0,417	0,760	0,819	0,815
IBk ($k=1$)	70,18	0,330	0,299	0,545	0,698	0,650	0,640

Tum metriklerde **Naive Bayes** en yuksek performansi sergilemistir. ROC-AUC degerinin 0,819 olmasi, modelin esik degerinden bagimsiz olarak guclu bir ayrim kapasitesine sahip oldugunu gostermektedir.

7.2. Karmasiklik Matrisleri

Table 5: Karmasiklik matrisleri – tahmin edilen sinif (sutun) ve gercek sinif (satir)

Gercek / Tahmin	J48		Naive Bayes		IBk ($k=1$)	
	Neg.	Poz.	Neg.	Poz.	Neg.	Poz.
tested_negative (500)	407	93	422	78	397	103
tested_positive (268)	108	160	104	164	126	142
Yanlis Negatif (FN)	108		104		126	
Yanlis Pozitif (FP)	93		78		103	

Klinik Yorum: Medikal tani uygulamalarinda yanlis negatif (FN) – yani hasta oldugu halde saglikli siniflandirilan bireyler – yanlis pozitiften cok daha maliyetlidir. Bu acidan

Naive Bayes, 104 FN ile en dusuk kacirma oranini sergilemis ve klinik guvenlik acisindan one cikmistir.

7.3. Sinifa Gore Detayli Performans

Table 6: Sinif bazinda Kesinlik, Geri Cagirma ve F-Measure degerleri

Algoritma	Sinif	Kesinlik	GC	F1	ROC-AUC
J48	tested_negative	0,790	0,814	0,802	0,751
	tested_positive	0,632	0,597	0,614	0,751
Naive Bayes	tested_negative	0,802	0,844	0,823	0,819
	tested_positive	0,678	0,612	0,643	0,819
IBk ($k=1$)	tested_negative	0,759	0,794	0,776	0,650
	tested_positive	0,580	0,530	0,554	0,650

7.4. Bias-Variance Analizi

Table 7: Algoritmaların bias-variance degerlendirmesi

Algoritma	Bias Durumu	Variance Durumu
J48	Orta bias: budama gereksiz dallanmayi engeller; egitim dogrulugu teste gore belirgin sekilde yuksektir.	Orta variance: agac yapisi verideki gurultuye kismen duyarlidir.
Naive Bayes	Yuksek bias: bagimsizlik ve Gaussian varsayimlari gercek iliskileri basitlestirir; ancak bu veri setine gorece iyi uymaktadır.	Dusuk variance: parametre sayisi azdir, overfitting riski dusuktur.
IBk ($k=1$)	Cok dusuk bias: egitim verisini ezberler.	Cok yuksek variance: test dogrulugu %70,18'e dusmektedir; gurultuye son derece duyarlidir.

8. J48 Karar Agaci Yorumu

WEKA'nin urettigi J48 agaci **20 yaprak** ve **39 dugume** sahiptir. Agacin kok bolunme ozniteligi $pl_{as} \leq 127$ 'dir; bu plazma glikozunun birincil ayirt edici oznitelik oldugunu dogrulamaktadır. Ikincil ayrim noktaları şunlardır:

- $\text{mass} \leq 26,4$: düşük VKI durumunda negatif sinifi guclu bicimde isaret eder (132 ornek, yalnızca 3 hata).
- $\text{age} \leq 28$: genc bireyler icin ek negatif gostergesi.
- $\text{pedi} > 0,56$ ve $\text{preg} > 6$: yuksek soyagaci skoru ve cok sayida hamilelik, pozitif sinifi guclendiren kuraldir.
- $\text{plas} > 157$: derin sag dalda guclu pozitif gostergesi (92 ornek, 12 hata).

Bu kurallar, klinisyenlerin kolayca yorumlayabilecegi beyaz-kutu bir karar destek yapisi sunmaktadir.

9. Sonuc ve Tartisma

9.1. Temel Bulgular

Bu calismada Pima Diyabetes veri seti uzerinde uc farkli makine ogrenmesi algoritmasi 10-katli capraz dogrulama ile degerlendirilmistir. Elde edilen baslica bulgular sunlardir:

1. **Naive Bayes en basarili modeldir.** %76,30 dogruluk, 0,819 ROC-AUC ve en dusuk yanlis negatif sayisi (104) ile klinik tercih kriterlerini en iyi karsilayan algoritma olmustur.
2. **Plazma glikozu (plas) baskin ozniteliktir.** Hem karar agaci yapisinde hem de siniflar arasi ortalama farklarinda belirleyici sekilde one cikmaktadir.
3. **IBk ($k=1$) asiri ogrenme nedeniyle en zayif genellemeyi sergilemistir.** k degeri artirilerek ve oznitelik normalizasyonu uygulanarak performans iyilestirilebilir.

9.2. Kisitlar

- Veri setinin yalnızca Pima Kizilderili kadinlarini kapsamasi genellestirilme gucunu azaltmaktadir.
- Sifir degerlerin sistematik bir imputation yontemiyle islenmemesi model kalitesini olumsuz etkileyebilir.
- Hiperparametre optimizasyonu yapilmamistir.

9.3. Gelecek Calismalar

- SMOTE ile sinif dengesizliginin giderilmesi.
- Grid-search ile hiperparametre ayari; SVM ve Random Forest gibi guclu siniflandiricilarin eklenmesi.
- Oznitelik secimi (wrapper/filter) ile boyut indirgeme.
- Farkli populasyonlarda dis dogrulama.

References

- [1] Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. *Proceedings of the Annual Symposium on Computer Application in Medical Care*, 261–265.
- [2] Kavakiotis, I., Tsave, O., Salifoglou, A., Maglaveras, N., Vlahavas, I., & Chouvarda, I. (2017). Machine learning and data mining methods in diabetes research. *Computational and Structural Biotechnology Journal*, 15, 104–116.
- [3] Sisodia, D., & Sisodia, D. S. (2018). Prediction of diabetes using classification algorithms. *Procedia Computer Science*, 132, 1578–1585.
- [4] Zou, Q., Qu, K., Luo, Y., Yin, D., Ju, Y., & Tang, H. (2018). Predicting diabetes mellitus with machine learning techniques. *Frontiers in Genetics*, 9, 515.
- [5] Khouardif, Y., & Bahaj, M. (2019). Heart disease prediction and classification using machine learning algorithms optimized by particle swarm optimization and ant colony optimization. *International Journal of Intelligent Engineering and Systems*, 12(1), 242–252.
- [6] Dua, D., & Graff, C. (2019). *UCI Machine Learning Repository – Pima Indians Diabetes Database*. University of California, Irvine. <https://archive.ics.uci.edu/ml/datasets/diabetes>
- [7] Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques* (4. baski). Morgan Kaufmann.
- [8] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3. baski). Morgan Kaufmann.